nx5 的模型，存在哪里?

当前固定方案：SSD 保存全量专家，统一内存缓存一部分；CPU 负责调度与读盘，GPU 直接读取缓存参与计算。

Orin NX 16GB Super
ARM CPU + GPU · 共用一块 DRAM

64K 上下文
65,536 token · 输入、历史、输出共用

176 / 256
每层专家缓存容量 · 不代表命中率

DSpark · 7 token
最多预测 7 个，交给主模型验证

1 NVMe SSD

模型文件长期保存在这里

全量路由专家
12.89 GiB
experts/ · Q3_K
40 层 × 256 = 10,240 个专家
gate / up / down 按专家打包

主模型非路由专家部分
stripped.gguf · 约 1.55 GiB
启动时加载 / 映射

DSpark 草稿权重
dspark-Q4_K_M.gguf
启动时加载 · 5 层草稿模型

其他模型资源
预热表：1,203 个常用专家
视觉编码器 / mmproj
本轮文字推理未加载视觉部分

缓存未命中
按需读取

命中时复用
保留页缓存

专家缓冲比
全量常驻少占
≈3.95
GiB

2 CPU / GPU 共享的同一块物理内存

系统可见 15,597.9 MiB ≈ 15.23 GiB

CPU · 调度、路由管理、I/O
8 个读盘线程向共享专家缓存写入数据

GPU · 专家矩阵运算、主模型验证
直接访问映射内存，无需再复制一整份专家缓存

动态专家缓存
8.94 GiB
9,157.5 MiB · 7,104 个槽位
CUDA 映射内存：CPU 写入，GPU 直读

每层窗口：176 × 40 = 7,040 槽
176 / 256 = 68.75% 的候选容量
另有 64 槽 prefill bank，所有层共用
未缓存的专家仍可按需读入，路由范围保持完整

主模型其余权重
1,575.24 MiB
含嵌入、注意力、共享专家等
CPU 映射 272.62 + CUDA 1302.62

DSpark 草稿权重
215.59 MiB
5 层 · Q4_K_M
CPU 映射 34.08 + CUDA 181.51

GDN 循环状态
502.5 MiB
30 个线性注意力层相关状态
当前 draft7 路径分配值

64K KV 缓存 · 合计 1,320 MiB ≈ 1.29 GiB
主模型 q8_0：680 MiB
草稿 f16：640 MiB

其他动态占用
计算缓冲、CUDA、系统、页缓存
检查点 ≤ 2；提示词缓存 ≤ 256 MiB

各内存区均来自同一池；框图面积不表示容量比例，文件映射和动态占用不可直接当作 RSS 相加。

3 一轮生成怎样经过这些部件

文字提示词
固定入口 → llama-cli

→ **DSpark 先预测**
最多 7 token，等待验证

→ **主模型并行验证**
每层选 8 专家 → 缓存 / 读盘 → GPU

→ **接受正确前缀并输出**
拒绝部分回退；同步更新 KV / 状态

批处理
batch 2048 · ubatch 8 · window rows 8

计算与采样
CUDA Graph 开 · Instruct · reasoning 关

默认采样参数
T 0.7 · top_p 0.95 · top_k 100

15.54 token/s
中文鹈鹕：38 输入 / 2,315 输出

14.22 token/s
8K 检索：8,218 输入 / 108 输出

≈1.10 GiB
验收最低可用内存；保护阈值 768 MiB

验收边界：已验证 64K 容量与约 8K 实际输入；尚未填满 64K。速率是特定任务实测，108-token 短回答不代表持续吞吐。

配置：minicpm-v47-64k.json

来源：64K 验收报告与启动日志

容量统一使用 MiB / GiB（二进制） · 当前为单请求 CLI

它擅长什么，哪里要留余地?

模型能力地图：以官方 Instruct 对比和 nx5 本轮实测为依据；“相对强弱”仅针对所列任务与对比模型。

35B-A3B · MoE
总量约 35.5B · 每 token 激活约 3B

40 层 · 混合注意力
30 层 GDN + 10 层全注意力

256 选 8 + 共享专家
每层独立路由 · 不裁剪专家候选集

当前部署 64K
官方配置上限 256K ≠ 本机已验证容量

1 模型架构：视觉编码 + 稀疏语言模型

文字直接进入语言模型

输入
文字
单图 / 多图 / 视频帧

→

视觉编码器
27 层 · SigLIP2 基础
视觉 token 压缩 4× / 16×

→

Qwen3.5 MoE 文本架构
GDN GDN GDN 全注意力 × 10
每层 MoE：256 个路由专家中选 8 个，另加共享专家

→

输出文字 / JSON / 代码
看图问答、文字回答
HTML / SVG 是代码生成任务

GDN 用循环状态保存信息；全注意力层使用 KV。MoE 减少单步计算量，但完整专家权重仍需保存。
nx5 当前固定入口仅验收文字输入；视觉编码器、图片 / 视频输入尚未纳入本轮部署验收。

2 能力强弱：看任务证据，不把不同榜单分数混成一个总分

相对强项
官方模型成绩 [1][2]

文档、OCR 与图表理解
OmniDocBench 1.6：94.24
官方同表其他模型最高：82.14
读文档是优势方向；不代表每个 OCR 子项都领先。

通用视觉理解
MMBench：91.72
官方同表其他模型最高：89.63
适合看图问答；精细定位仍要单独评估。

中文知识与视频理解
CMMLU：90.21 · Video-MME：76.40
这两项在官方所列对比中领先。

相对短板
官方模型成绩 [1][2]

代码生成
LiveCodeBench-v6：56.57
同表 Gemma-4 31B：71.24
有代码能力，但复杂实现与调试不是相对强项。

GUI 元素定位
ScreenSpot：86.99
同表 Qwen3.8 27B：93.31
能理解截图，不等于总能准确点击目标。

复杂指令遵循
IFBench：47.67 · Gemma-4 31B：54.33
约束较多时，输出格式和细节需要核验。

nx5 的实际表现
当前量化与运行配置 [4]

有原文的字段检索：本次通过
8,218-token 输入，六个核验码 6/6 正确
JSON 可解析，未漏项或添加字段
属于一次检索样本，不能推成全面长上下文成绩。

SVG 动画：本次未通过
能生成完整 HTML，但车轮旋转中心错误
关闭 DSpark 后仍出现定位问题
这次 8K → 64K 的 HTML 内容逐字节相同。

多模态与工具：尚未验收
图片 / 视频问答、工具调用、HTTP 服务
官方支持的能力不等于本机固定入口已提供。

官方分数口径：35B-A3B、Instruct；视觉取 4× 压缩、Video-MME 无字幕。分数仅可在同一榜单内对比。
以上“官方成绩”来自官方检查点对比表，并非 nx5 混合 Q3_K / GGUF 量化版本的实测分数。

3 在这台 nx5 上怎么用

现在可优先使用
带原文的字段抽取 / 检索
本轮已有实际样本通过

值得下一步验收
文档 OCR / 截图 / 视频问答
模型优势方向，需接入视觉链路

生成后必须检查
复杂代码 / SVG / 动画
实际运行、看图检查、再修正

当前输出范围
文字、结构化文本与代码
当前链路不提供语音或图像生成

质量边界
未做原始高精度权重与当前量化的全面质量对照，不能量化能力损失，也不能宣称完全无损。
64K 只通过容量与约 8K 实际输入验证；完整 64K 历史、多轮常驻质量尚未验证。

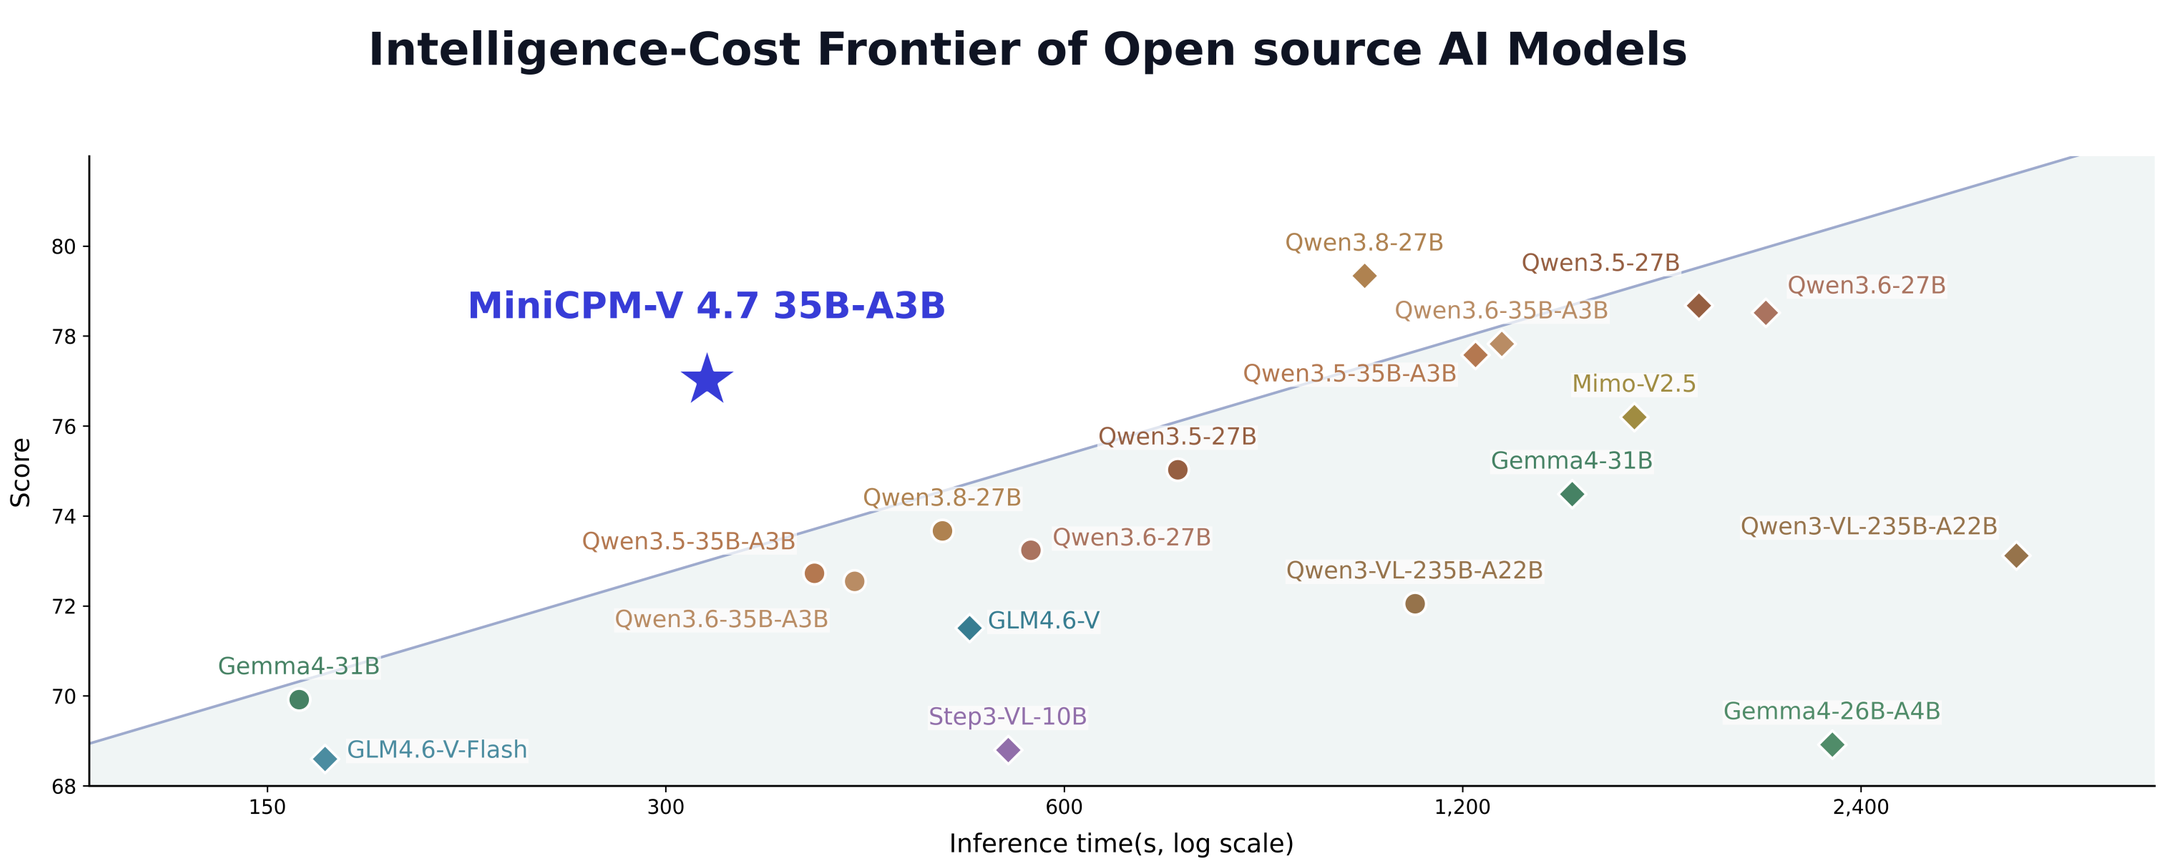
[1] 官方视觉评测表　[2] 官方语言评测表　[3] 官方模型配置　[4] nx5 本轮验收报告

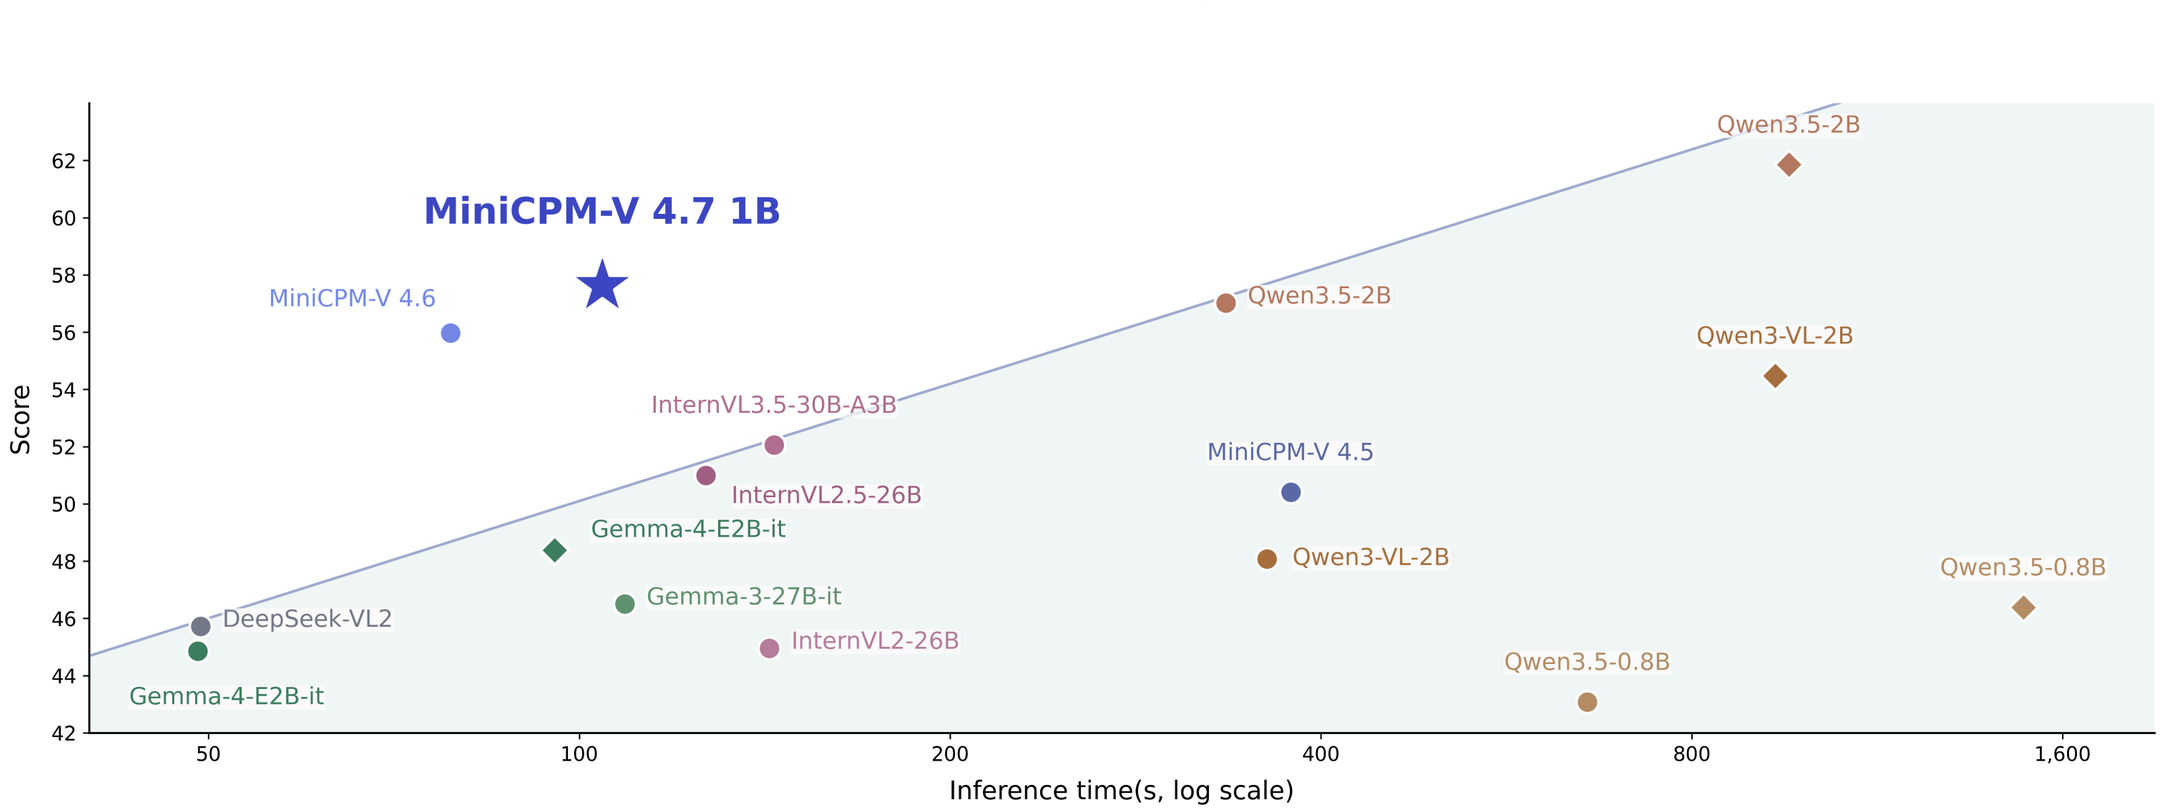
模型能力与视觉压缩说明：OpenBMB 官方指南

强弱判断范围：官方所列对比 + 本轮本机证据

官方对比：性能与推理效率

完整保留官方原图；上半图是本机对应的 35B-A3B 型号，下半图为 1B 型号。





1. Average time and score over MMStar, MMMU-Pro, Charxiv_Reasoning, BLINK and MathVista; 2. ★ and ●: Instruct mode; ◆: Thinking mode

横轴是官方评测的推理时间（对数刻度），纵轴是评测得分；不能换算成本机的 token/s。
图中的 Instruct / Thinking 模式以原图图例为准；nx5 固定方案使用 Instruct、reasoning 关闭。

来源：OpenBMB / MiniCPM-V 官方原图（点击查看）

官方结果不代表 nx5 当前量化部署的实测成绩

官方对比：视觉、文档与视频能力

35B-A3B · Instruct 模式 · 同时展示 4× 与 16× 视觉 token 压缩配置。

Task	Benchmark	MiniCPM-V4.7		Qwen3.6	Qwen3.6	Qwen3.8	Gemma-4
Size		35B-A3B		35B-A3B	27B	27B	31B
Visual Token Compression Ratio		4x	16x	4x	4x	4x	9x
General	MMBench	**91.72**	90.87	86.76	85.11	85.91	89.63
	MMStar	**80.67**	80.13	76.00	74.40	75.13	76.47
	MMT-Bench	75.47	75.12	72.53	73.58	72.82	**75.73**
	SimpleVQA	54.14	51.41	**54.40**	52.75	50.81	52.24
STEM	MMMU	**80.22**	80.00	77.44	78.44	76.00	75.33
	MathVista	**88.00**	87.30	84.40	84.40	84.40	78.50
	MMMU-Pro	69.71	67.66	69.88	**69.97**	69.74	64.02
	MathVerse_MINI	**86.45**	84.80	82.74	81.88	84.37	75.58
	MathVision	74.24	72.93	74.24	75.03	**78.22**	69.28
Document, OCR & Chart	OCRBench	**91.20**	90.40	86.00	86.80	83.90	85.40
	OCRBench_v2	**68.47**	65.67	66.50	65.49	63.95	54.14
	OmniDocBench_v1.6	**94.24**	93.25	80.17	82.14	80.36	79.17
	CharXiv_Reasoning	**75.60**	69.20	67.50	68.50	70.70	65.00
	CCOCR	81.14	78.29	82.33	82.34	**82.49**	76.91
	TextVQA_VAL	**84.99**	81.72	83.98	81.31	79.60	81.21
Multi-Image	BLINK	**70.33**	68.12	66.91	66.65	67.81	69.33
	MMSI-Bench	16.00	15.20	10.70	9.00	10.90	**18.70**
Hallucination	Hallusion-Bench	63.83	**64.42**	62.06	62.35	60.98	61.65
	MMHal-Score	4.72	4.67	4.96	3.17	**5.03**	4.18
	MMHal-Hallrate ↓	**21.88**	22.92	25.00	**21.88**	**21.88**	27.08
Grounding & GUI	RefCOCO	90.93	89.61	**90.97**	90.91	88.77	81.47
	ScreenSpot	86.99	85.01	92.94	90.73	**93.31**	83.75
Instruction Following	MM-IFEval	65.41	64.62	62.85	65.77	68.03	**69.59**
Video-Understanding	Video-MME(w/o subs)	**76.40**	74.70	75.70	70.20	73.40	74.10
	LongVideoBench	**68.90**	67.60	63.10	67.70	60.90	60.70
	MotionBench	68.12	68.02	67.87	**69.11**	65.11	62.67

MiniCPM-V 4.7 supports mixed 4x/16x visual token compression, with either 4x or 16x selectable. Other models support only fixed compression ratios.
Results are from public reports and our local evaluation using official checkpoints.
We evaluate the models in instruct mode.

请在同一行内比较不同模型；不同榜单的分数不能直接当作统一的能力刻度。
本机尚未验收图片 / 视频输入；这张表用于了解模型本身的能力方向。

来源：OpenBMB / MiniCPM-V 官方原图（点击查看）

官方结果不代表 nx5 当前量化部署的实测成绩

官方对比：语言、代码与工具调用

35B-A3B · Instruct 模式 · 保留官方检查点的完整对比结果。

Task	Benchmark	MiniCPM-V4.7	Qwen3.6	Qwen3.6	Qwen3.8	Gemma-4
Size		**35B-A3B**	**35B-A3B**	**27B**	**27B**	**31B**
Knowledge	CMMLU	**90.21**	89.34	89.52	87.66	79.76
	MMLU-Pro	83.45	84.11	**84.52**	82.40	84.43
	SuperGPQA	61.23	63.37	**63.71**	60.41	62.23
Instruction Following	IFBench	47.67	35.33	44.67	43.67	**54.33**
Math	AIME26@avg16	76.46	74.17	**80.42**	76.04	76.88
Coding	LiveCodeBench-v6	56.57	54.29	59.05	63.62	**71.24**
Tool call	BFCL-V4	60.06	60.20	60.66	**63.72**	61.96
	τ^2-Bench	**84.65**	79.65	79.70	66.90	67.35

Results are from public reports and our local evaluation using official checkpoints.
We evaluate the models in instruct mode.

官方评测与 nx5 的混合量化、运行参数不同；尚未做高精度权重与当前部署的全面质量对照。
本机证据：configs/minicpm-v47-64k.json；docs/08-nx5-64k-fixed-20261021.md。

来源：OpenBMB / MiniCPM-V 官方原图（点击查看）

官方结果不代表 nx5 当前量化部署的实测成绩